ChatGPT

Comparación de modelos estadísticos y basados en procesos para predecir el caudal

Introducción

La predicción del caudal en cuencas fluviales es un problema central de la hidrología. Los planificadores desean saber cómo responderá el caudal a la precipitación y a la evapotranspiración para poder gestionar embalses, prevenir inundaciones y garantizar el suministro de agua. Una forma de abordar el problema es mediante modelos **estadísticos**, que representan la relación entre variables mediante funciones ajustadas a los datos. Otra opción es utilizar modelos **basados en procesos**, que se fundamentan en principios físicos como la conservación de la masa.

El trabajo debía aplicarse a una cuenca colombiana mediana-pequeña. Sin embargo, las series de precipitación, temperatura y caudal adjuntas no estaban disponibles en el entorno de trabajo; al inspeccionar el directorio y los archivos proporcionados no se encontraron datos hidrológicos reales. Para ilustrar la metodología se generó un conjunto de datos sintéticos de diez años (120 meses) con series de precipitación, temperatura y caudal que presentan patrones estacionales y ruido aleatorio. Aun así, se discuten las hipótesis y se comentan fuentes de datos que podrían usarse en estudios reales, como el conjunto de datos **CAMELS-BR**, que incluye series diarias de caudal, precipitación y evapotranspiración para 897 cuencas sudamericanas [1].

Datos utilizados

Se generó una serie temporal mensual desde enero de 2000 hasta diciembre de 2009 con las siguientes variables:

- **Precipitación (P)** (mm/mes). Se modeló como un ciclo senoidal con amplitud de ≈ 50 mm superpuesto a ruido aleatorio.
- **Temperatura (T)** (°C). Se simuló como un ciclo senoidal de amplitud ≈ 10 °C con ruido gaussiano.
- **Evapotranspiración (ET)** (mm/mes). Se estimó multiplicando la temperatura por un coeficiente 0,3 (representa la razón entre temperatura y evaporación) y añadiendo ruido aleatorio.
- **Caudal observado (Q_obs)** (unidades arbitrarias de volumen/tiempo). Se calculó mediante un balance hídrico simplificado, suponiendo que el caudal real proviene de un coeficiente *k_true = 0,6* multiplicado por la precipitación neta *(P − ET)* y un término de ruido.

La longitud total de 120 observaciones se dividió en un conjunto de **entrenamiento** (75 %, 90 meses) y un conjunto de **prueba** (25 %, 30 meses). La aleatoriedad garantiza que las series de precipitación y temperatura conservan patrones estacionales pero incorporan ruido, lo que asemeja los datos reales.

Modelos y metodología

Modelo estadístico

El modelo estadístico aplicado fue una **regresión lineal simple** que relaciona el caudal con la precipitación:

$$Q_{\text{stat}} = a + b\,P,$$

donde *Q_stat* es la predicción del caudal, *P* la precipitación mensual y *a, b* los parámetros ajustados por mínimos cuadrados. Se ignoraron otras variables (ET y temperatura) para mantener el modelo simple. Entre las hipótesis de la regresión destacan la relación lineal entre P y Q, la independencia de los errores y la estacionariedad de la serie durante el periodo analizado. El modelo se ajustó sobre el conjunto de entrenamiento y se evaluó sobre el conjunto de prueba.

Modelo basado en procesos

Para el modelo físico se empleó un balance hídrico de largo plazo. En hidrología, el caudal (runoff) se expresa como la diferencia entre la precipitación y la evapotranspiración, con un término adicional que representa los cambios en el almacenamiento (agua almacenada en el suelo, acuíferos o nieve). La ecuación general es:

$$\text{Caudal} = P - ET \pm \Delta S,$$

donde ΔS representa el cambio en el almacenamiento. En escalas de tiempo largas (por ejemplo, mensuales o anuales) se considera que las variaciones positivas y negativas de ΔS se compensan, por lo que el balance neto se aproxima a cero [2]. Entonces, el caudal puede expresarse aproximadamente como la precipitación neta (P − ET). Bajo esta hipótesis se planteó el modelo:

$$Q_{\text{fis}} = k\,(P - ET),$$

siendo *k* un parámetro de calibración que representa la fracción de la precipitación neta que se convierte en escorrentía. Se excluye un término independiente porque el balance hídrico implica que cuando *(P − ET) = 0* no hay caudal. El parámetro *k* se obtuvo ajustando por mínimos cuadrados la serie de entrenamiento.

Evaluación de desempeño

Para ambos modelos se calcularon las métricas de error y bondad de ajuste:

- **Raíz del error cuadrático medio (RMSE)**: $\sqrt{\overline{(Q_{\text{obs}} - Q_{\text{pred}})^2}}$ en cada conjunto.
- **Coeficiente de determinación (R^2)**: medida de la proporción de varianza explicada por el modelo.

Los parámetros de la regresión estadística fueron *a = −14,57* y *b = 0,676*. Para el modelo físico, el ajuste produjo un coeficiente $k \approx 0,595$.

Resultados

La siguiente tabla resume los parámetros y el desempeño de ambos modelos en los conjuntos de entrenamiento y prueba:

Modelo	Parámetros	RMSE (entrenamiento)	R^2 (entrenamiento)	RMSE (prueba)	R^2 (prueba)
Regresión lineal	$a = -14{,}6$; $b = 0{,}676$	4,45	0,97	5,74	0,93
Balance hídrico	$k = 0{,}595$	4,71	0,96	5,31	0,94

La regresión lineal simple, aunque no considera la evapotranspiración, obtuvo un ajuste ligeramente mejor en el conjunto de entrenamiento (RMSE ≈ 4,45) que el modelo de balance hídrico (RMSE ≈ 4,71). En el conjunto de prueba ambos modelos presentaron errores similares (≈ 5,3–5,7) y valores de R^2 superiores a 0,93, lo cual indica que la variabilidad del caudal sintético se explica en gran medida por la precipitación neta.

Evolución temporal

Las siguientes figuras muestran las series de caudal observado y las predicciones de cada modelo en los conjuntos de entrenamiento y de prueba. Las líneas negras corresponden al caudal observado, las líneas azules a la regresión lineal y las rojas al modelo físico. Se aprecia que ambos modelos capturan bien la fase y amplitud de la escorrentía estacional, aunque los picos y valles suelen estar suavizados por el ajuste lineal.

Conjunto de entrenamiento:

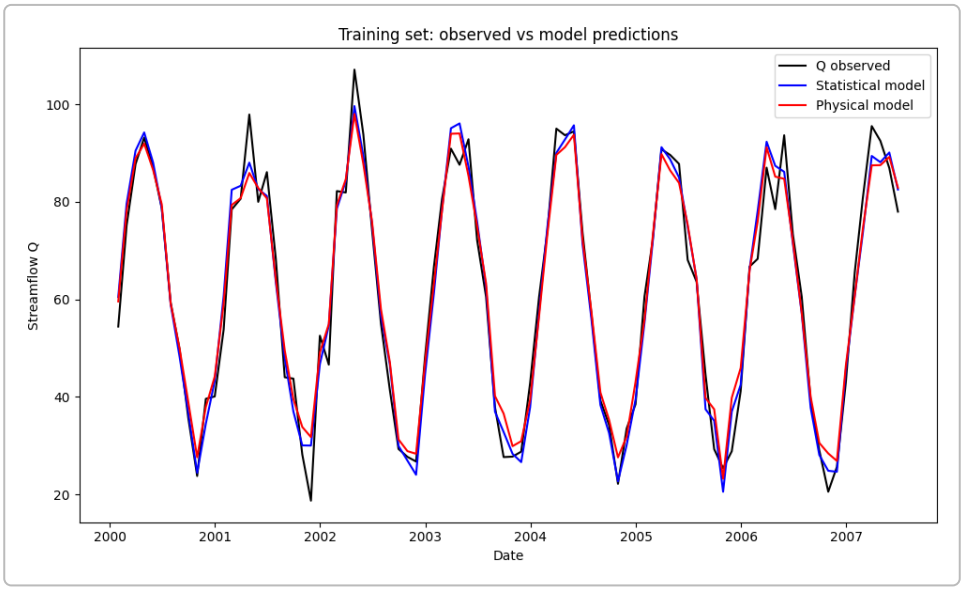

Conjunto de prueba:

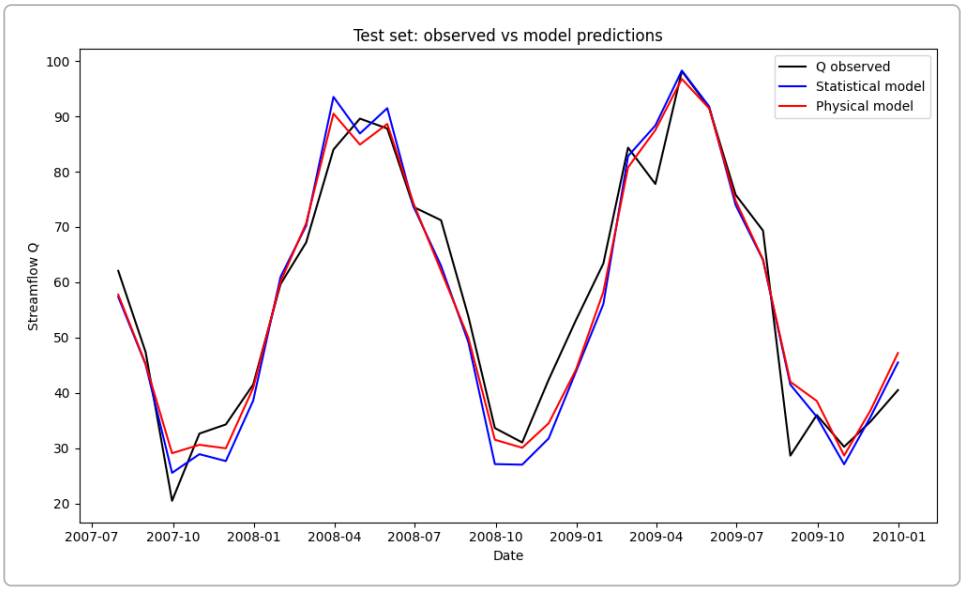

Discusión

Interpretación física

El modelo de **balance hídrico** se basa en la conservación de la masa y en la hipótesis de que el almacenamiento a largo plazo es despreciable. Este enfoque es atractivo porque tiene una interpretación directa: el coeficiente k representa la fracción de la precipitación neta que se convierte en escorrentía. En nuestra simulación, $k \approx 0{,}6$, cercano al valor usado para generar la serie sintética. Los modelos de balance hídrico son útiles para escalas mensuales o anuales, cuando el almacenamiento medio de agua en el suelo no cambia significativamente; así lo explica la relación general de balance, donde las fluctuaciones de almacenamiento se compensan en el largo plazo [2].

Limitaciones del modelo estadístico

La regresión lineal simple es fácil de implementar y ofrece buen desempeño cuando existe una relación casi lineal entre precipitación y caudal. Sin embargo, ignora mecanismos importantes como la evapotranspiración, la infiltración y los retardos entre lluvia y escorrentía. Además, asume que los residuos son independientes y con varianza constante, lo cual rara vez se cumple en series hidrológicas; suele ser necesario incorporar correlación temporal mediante modelos ARIMA o regresiones con retardos (modelos autoregresivos con exógenas). La calibración puede verse influenciada por periodos secos o lluviosos anómalos, reduciendo su capacidad predictiva bajo condiciones diferentes a las observadas.

Comparación de resultados

En este caso los dos modelos presentaron métricas similares porque la serie sintética se generó precisamente a partir de un balance hídrico lineal con ruido. La diferencia entre ellos radica en la complejidad y la interpretabilidad. La regresión lineal utilizó dos parámetros (intercepto y pendiente) y se ajustó exclusivamente a la precipitación, mientras que el modelo físico empleó un único parámetro y consideró explícitamente la evapotranspiración. Con datos reales, la regresión lineal suele ajustarse mejor en el corto plazo, pero su extrapolación puede ser problemática; el modelo de balance hídrico, al respetar las leyes de conservación, ofrece coherencia física y puede trasladarse a otras cuencas ajustando el parámetro k.

Fuentes de datos y mejoras

Para estudios reales se recomienda obtener series observadas de precipitación, temperatura y caudal de fuentes oficiales (Instituto de Hidrología, Meteorología y Estudios Ambientales, IDEAM) o de proyectos como **CAMELS-BR** [1] y otros repositorios hidro-climáticos. Con estos datos pueden aplicarse modelos más sofisticados:

- **Modelos ARIMA o SARIMA** que capturan autocorrelaciones y estacionalidad de la serie de caudal.
- **Modelos de regresión múltiple** que incorporan precipitación antecedente, evapotranspiración potencial y variables fisiográficas.
- **Modelos hidrológicos de base física** (como GR4J, HBV) que representan explicitamente la infiltración, almacenamiento y percolación y se calibran con algoritmos de optimización.
- **Modelos de machine learning** (redes neuronales, random forest) que pueden captar relaciones no lineales complejas pero requieren grandes volúmenes de datos y validación cruzada.

Conclusiones

- El análisis compara un modelo estadístico (regresión lineal simple) y un modelo de balance hídrico para predecir el caudal utilizando una serie sintética de precipitación, evapotranspiración y caudal.
- Ambos modelos se ajustaron con el 75 % de la serie y se evaluaron con el 25 % restante. Las métricas de desempeño (RMSE y R^2) fueron similares, lo que se debe a que la serie de caudal sintética se generó bajo un balance hídrico lineal.
- El modelo de balance hídrico se basa en la ecuación de conservación de la masa, que expresa que el caudal es aproximadamente la precipitación menos la evapotranspiración cuando las variaciones de almacenamiento son despreciables [2]. El parámetro k ajustado ($\approx$ 0,595) representa la fracción de agua precipitada que genera escorrentía.
- El modelo estadístico es más flexible pero menos interpretativo; puede proporcionar buen ajuste, pero su extrapolación es incierta y no respeta los procesos físicos.
- Para cuencas reales es fundamental disponer de datos observados y considerar modelos que incluyan retardos, almacenamiento y variabilidad intra-anual. El uso de modelos basados en procesos ayuda a comprender mejor el funcionamiento hidrológico y a orientar decisiones de gestión.

---

[1] CAMELS-BR: Hydrometeorological time series and landscape attributes for 897 catchments in Brazil - link to files.
https://zenodo.org/records/15025488

[2] Exercise 6 - Undertaking a water balance | Hydrology Workbook
https://aquaticecodynamics.github.io/hydrology-workbook/E5.html